

Aplicação de Processamento Digital de Sinais (DSP) no Processamento de Imagem Digital para Identificação das Quadras de Novos Loteamentos Urbano

line 1: Saul Vione Winik

line 2: GEDRE

line 3: Universidade Federal de Santa Maria

line 4: Santa Maria, Brazil

line 5: saul.winik@gmail.com

line 1: Carlos Henrique Barriquello

line 2: GEDRE

line 3: Universidade Federal de Santa Maria

line 4: Santa Maria, Brazil

line 5: carlos.barriquello@ufsm.br

Abstract — Com o crescimento acelerado das áreas urbanas, a precisão e eficiência no planejamento, fiscalização e vistoria desses espaços tornam-se essenciais. Utilizando técnicas como a detecção de cores específicas, filtros de convolução matricial e Gaussianos além de algoritmos de segmentação, o estudo demonstra como é possível automatizar a identificação das quadras de loteamentos. Além disso, aborda os desafios enfrentados sem esse tipo de solução, como a escassez de mão de obra para vistorias, variações de iluminação e a complexidade das cenas urbanas, propondo soluções para superá-los. Os resultados demonstram que o uso de DSP no processamento de imagens digitais pode melhorar significativamente a velocidade, precisão e eficiência do planejamento urbano, contribuindo para o desenvolvimento de cidades mais organizadas e sustentáveis.

Keywords—DPS, DIP, mensuração, identificação.

I. INTRODUCTION

O crescimento acelerado das áreas urbanas nas últimas décadas trouxe desafios significativos para o planejamento e gestão dessas regiões. A precisão e a eficiência no planejamento, fiscalização e vistoria de áreas urbanas são essenciais para garantir um desenvolvimento sustentável e organizado [1]. Neste contexto, a utilização de técnicas avançadas de processamento digital de sinais (DSP) para análise de imagens urbanas emerge como uma solução promissora.

A detecção de cores específicas é uma técnica amplamente utilizada em processamento de imagens para a identificação e segmentação de objetos em ambientes complexos [6]. No contexto urbano, essa técnica pode ser aplicada para diferenciar elementos como calçadas, ruas e áreas verdes, facilitando a análise e o planejamento urbano [15]. A combinação dessa técnica com filtros de convolução matricial e Gaussianos permite uma melhoria significativa na precisão da detecção, reduzindo erros e aumentando a eficiência do processo [7].

Algoritmos de segmentação são fundamentais para a automação no planejamento urbano. Eles permitem dividir imagens em segmentos distintos, cada um correspondendo a diferentes elementos da cena urbana, como edifícios, ruas e espaços abertos [13]. A aplicação de algoritmos de segmentação em imagens urbanas possibilita a obtenção de informações detalhadas sobre a estrutura e a distribuição

espacial das áreas urbanas, contribuindo para um planejamento mais eficiente e preciso [3].

A escassez de mão de obra para vistorias e as variações de iluminação são desafios comuns enfrentados na gestão urbana tradicional. A automação, utilizando técnicas de DSP, pode mitigar esses problemas, oferecendo uma solução robusta e adaptável às diversas condições encontradas em ambientes urbanos [12]. A capacidade de lidar com variações de iluminação é especialmente importante para garantir a consistência e a precisão das medições, independentemente das condições ambientais [9].

A complexidade das cenas urbanas, caracterizada pela diversidade de elementos e pela dinâmica dos espaços, representa um desafio adicional para o planejamento urbano. Soluções baseadas em DSP podem abordar essa complexidade de maneira eficaz, permitindo a análise detalhada e a gestão eficiente dos espaços urbanos [8]. Este estudo demonstra como a aplicação dessas técnicas pode superar as limitações dos métodos tradicionais, proporcionando resultados mais precisos e confiáveis.

Este estudo propõe a automação da identificação de quadras de loteamentos urbanas em sua fase de conclusão através da análise de imagens obtidas gratuitamente do *googlemaps*. Sendo uma solução de baixo custo, maior velocidade e suscetível a menor erros grosseiros.

II. METODOLOGIA

Para a execução deste estudo, inicialmente foi realizada a captura de imagens utilizando a plataforma gratuita Google Maps, seguindo critérios rigorosos para assegurar a consistência dos dados coletados. As imagens foram obtidas a partir de uma altitude uniforme e com dimensões padronizadas, garantindo a comparabilidade entre os diferentes cenários analisados.

A. Pré-Processamento

Posteriormente, foram aplicadas quatro técnicas de Processamento Digital de Sinais (DSP) para o pré-tratamento das imagens, a aplicação de uma máscara com limites inferiores e superiores com a tonalidade básica dos materiais aplicados nas calçadas. A Figura 1 demonstra o resultado obtido após a aplicação da máscara referente a tonalidade de cor.



Fig. 1. Imagem Original x Imagem Após Aplicação da Mascará

Na sequência transformando a imagem resultante em tons de cinza, foram aplicados três filtros para suavização: filtro de *anti-aliasing*, filtro de passagem baixa gaussiano e filtro de convolução matricial. O filtro de *anti-aliasing* tem como objetivo principal realizar a distorção visual que ocorre quando linhas ou padrões finos são representados em uma resolução insuficiente. Ao aplicar este filtro, os detalhes de alta frequência são suavizados, resultando em uma transição mais gradual entre os diferentes tons de cinza na imagem. Resultando numa melhora da qualidade visual, tornando as bordas menos serrilhadas e as transições de intensidade mais suaves e naturais. Conforme a Figura 2 ilustra.




Fig. 2. Imagem em Tons de Cinza

Quando uma imagem é submetida a um filtro de passagem baixa gaussiano simétrico rotacional com uma matriz de tamanho 30x30 e desvio padrão equivalente a 1, o objetivo é suavizar a imagem ao reduzir os ruídos de alta frequência e detalhes finos, resultando em uma aparência mais homogênea. A simetria rotacional do filtro assegura que a operação seja aplicada uniformemente em todas as direções da imagem, mantendo a uniformidade do processo de suavização.

A aplicação da convolução matricial, um processo fundamental em processamento de imagens, onde a multiplicação numérica ocorre entre elementos de mesma posição em duas matrizes: a matriz da imagem original e a matriz do filtro. Este processo começa com a sobreposição do filtro sobre uma região específica da imagem. Para cada posição, os valores dos pixels da matriz da imagem são multiplicados pelos valores correspondentes na matriz do filtro. As multiplicações resultantes são somadas, e essa soma é então dividida pelo número de elementos da matriz do filtro, calculando-se a média. O valor médio resultante substitui o valor do pixel central da região filtrada. Este processo é repetido para cada pixel da imagem, ajustando o valor de cada pixel com base nos valores dos pixels vizinhos. Este método não apenas suaviza a imagem, reduzindo o ruído, mas também atenua as bordas de altas frequências, suavizando as transições abruptas de intensidade entre diferentes áreas da imagem. Como resultado, a imagem processada apresenta menos ruído e bordas mais suaves [14]. A Figura 3 ilustra a aplicação destes dois últimos filtros.




Fig. 3. Resultado dos Filtros Gaussianos e Convolução Matricial

B. Segmentação da Imagem

Realizar o processo de segmentação implica dividir uma imagem em porções menores, de modo a identificar e caracterizar segmentos distintos com base em informações extraídas da própria imagem. O critério de término do processo ocorre quando os objetos de interesse na imagem foram isolados. O resultado é um conjunto de pixels que define o contorno de uma região ou todos os seus pontos, dependendo da aplicação desejada e dos dados relevantes que se pretende destacar na imagem [4].

Para chegar ao resultado aplicou-se a técnica de segmentação de detecção de bordas. Uma borda é uma transição abrupta entre duas regiões na imagem, onde as propriedades de níveis de cinza variam significativamente. A detecção automática de bordas pode ser realizada utilizando operadores de derivadas locais conhecidos como gradientes. Esses gradientes são implementados através do uso de máscaras, também chamadas de janelas, que são filtros de diferentes tamanhos. Essas máscaras são aplicadas na imagem para calcular gradientes locais, destacando as variações de intensidade que indicam a presença de bordas [4],[10].

O método escolhido foi o de Prewitt que utiliza duas máscaras: uma para detectar gradientes na direção horizontal e outra na direção vertical. Cada máscara é uma matriz pequena de números que são aplicados a cada pixel da imagem através de operações de convolução. A convolução é uma multiplicação elemento a elemento seguida de uma soma, onde o resultado é atribuído ao pixel central da região em análise [11].




Fig. 4. Bordas Detectadas Pelo Método de Prewitt

O processo de eliminação de contornos fracos e descontínuos utilizando dilatação das bordas detectadas consiste em um passo básico no processamento de imagens para melhorar a continuidade e a robustez das bordas identificadas. Aplicando o Método de Prewitt obtém-se uma imagem binária onde os pixels correspondentes às bordas têm valores distintos de zero. Para melhorar a qualidade da

detecção de bordas, aplica-se então a operação de dilatação sobre essa imagem binária. Aplicando um processo morfológico que expande as regiões brancas na imagem, ou seja, os pixels que representam as bordas.

Essa operação percorre a imagem com um elemento estruturante, geralmente uma pequena matriz quadrada, e substituindo cada pixel na imagem de saída pela intensidade máxima encontrada na vizinhança definida pelo elemento estruturante na imagem de entrada. Preenchendo as lacunas pequenas e conecta segmentos de bordas que são próximos o suficiente para serem considerados como parte de uma mesma borda contínua [5]. Conforme Figura 5.




Fig. 5. Dilatação dos Contornos das Bordas Detectadas

Utilizando a função *imfill*, procedeu-se ao preenchimento dos contornos contínuos destacados na Figura 5. A função *imfill* é utilizada para preencher regiões de objetos na imagem que são delimitadas por bordas contínuas, permitindo a manipulação e análise posterior dessas áreas de forma mais eficiente e precisa.




Fig. 6. Preenchimento das Quadras

Para remover as bordas de uma imagem binária, o processo geralmente envolve a aplicação de operações morfológicas para eliminar pixels adjacentes às bordas da imagem que não pertencem aos objetos de interesse. Isso é realizado para limpar artefatos indesejados que podem surgir durante a detecção de bordas ou segmentação inicial da imagem. Uma abordagem comum é aplicar uma operação de erosão, que consiste em desgastar ou diminuir regiões brancas (objetos) na imagem, reduzindo sua área conforme um elemento estruturante define o efeito. Isso ajuda a suavizar as bordas e remover pixels isolados ou pequenas saliências que não representam corretamente os objetos principais na imagem binária.

A função *imerode* do MATLAB é uma operação morfológica utilizada para encolher ou erodir regiões de objetos em imagens binárias. Ela opera percorrendo a imagem com um elemento estruturante, como um disco ou um quadrado, e substituindo cada pixel na imagem de saída pela

intensidade mínima encontrada na vizinhança definida pelo elemento estruturante na imagem de entrada.

Além da erosão para remover bordas indesejadas, é comum aplicar uma etapa de limiarização para remover objetos menores que um determinado tamanho. Por exemplo, para remover objetos com área menor que 1100 pixels em uma imagem binária, pode-se usar operações de análise de região ou funções específicas do MATLAB, como *bwareaopen*, que identifica e remove objetos com áreas abaixo do limiar especificado. Isso é útil para eliminar ruídos ou pequenos artefatos que não são relevantes para a análise ou processamento subsequente da imagem binária.

A Figura 7 ilustra o resultado após a limpeza da imagem descrita anteriormente.




Fig. 7. Resultado Final do Processo de Segmentação

III. RESULTADOS

O Processamento de Imagem Digital apresentado até o momento resulta na numeração das quadras, seguindo ordem da esquerda para a direita. Conforme ilustra a Figura 8.




Fig. 8. Identificação 01

Nos resultados da Figura 8, observa-se que as quadras 1 e 4 apresentaram duas irregularidades em suas esquinas, onde o solo adjacente possui pigmentação semelhante à do passeio. A quadra 2, por sua vez, não demonstrou nenhuma irregularidade significativa em seus dados. Entretanto, a quadra 3 exibiu uma modificação em sua borda inferior devido à presença de objetos localizados na calçada em frente a um terreno em construção. Apesar de algumas variações nas bordas das quadras, o resultado geral foi satisfatório.




Fig. 9. Identificação 02

A avaliação em outro loteamento, conforme ilustrado na Figura 9, revelou que a vegetação que cobria parte do passeio interferiu na conclusão da delimitação da quadra 1. As demais quadras na imagem apresentaram poucas distorções em seus perímetros, embora todas tenham sido preenchidas, exceto a primeira quadra.

Esses resultados destacam a robustez do método utilizado para delimitar quadras urbanas, mesmo diante de desafios como variações na pigmentação do solo e interferências de elementos naturais como a vegetação. A capacidade de identificar e corrigir automaticamente irregularidades nas bordas das quadras contribui para a precisão e confiabilidade do sistema, essenciais para aplicações práticas em planejamento urbano e gestão territorial.

IV. CONSIDERAÇÕES FINAIS

Considerando que as imagens originais foram adquiridas por meio de uma plataforma de aquisição de dados de acesso livre, caracterizadas pela sua resolução limitada e pela falta de critérios rigorosos de análise, os resultados obtidos demonstram uma adequada aplicação das técnicas de processamento de imagem digital, especialmente em relação à identificação e medição de áreas e perímetros de quadras urbanas. A utilização de técnicas de Processamento Digital de Sinais (DSP) permitiu melhorar significativamente a precisão e eficiência do planejamento urbano, apesar das limitações inerentes aos dados de entrada.

No entanto, para estudos subsequentes, planeja-se a implementação de métodos mais robustos de processamento de imagem. Essa próxima etapa visa não apenas aprimorar a precisão das medições, mas também realizar uma comparação detalhada com resultados obtidos por meio de equipamentos técnicos especializados, como dispositivos de sensoriamento

remoto de alta resolução e sistemas de georreferenciamento de precisão. Essa abordagem metodológica mais sofisticada e controlada possibilitará uma validação mais rigorosa das técnicas propostas, contribuindo para uma maior confiabilidade e acurácia nas análises de planejamento urbano e gestão de áreas urbanas. A integração de DSP com tecnologias avançadas de sensoriamento remoto promete não apenas ampliar as capacidades de análise, mas também abrir novas possibilidades para o desenvolvimento de cidades mais organizadas e sustentáveis através de dados mais precisos e confiáveis.

REFERENCES

- [1] Batty, M. (2018). *Inventing future cities*. MIT Press.
- [2] Chen, L., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2020). DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs. *IEEE transactions on pattern analysis and machine intelligence*, 40(4), 834-848.
- [3] Comaniciu, D., & Meer, P. (2002). Mean shift: A robust approach toward feature space analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(5), 603-619.
- [4] Gonzalez, R. C., & Woods, R. E. (2000). *Digital Image Processing*. Prentice Hall.
- [5] Gonzalez, R. C., & Woods, R. E. (2008). *Digital Image Processing* (3rd ed.). Prentice Hall.
- [6] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.
- [7] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [8] He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask R-CNN. In *Proceedings of the IEEE international conference on computer vision* (pp. 2961-2969).
- [9] Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 3431-3440).
- [10] Padilha, A. C. M. (2007). *Processamento Digital de Imagens*. Érica.
- [11] Prewitt, J. M. S. (1970). Object Enhancement and Extraction. In *Picture Processing and Psychopictorics* (pp. 75-149). Academic Press.
- [12] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention* (pp. 234-241). Springer, Cham.
- [13] Shi, J., & Malik, J. (2000). Normalized cuts and image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(8), 888-905.
- [14] Winik, S. V. (2018). *Estudo Experimental e Modelagem Matemática para Secagem de Grãos de Milho em Camada Fina*. Dissertação de Mestrado, Universidade Federal do Rio Grande do Sul.
- [15] Zhang, Y., Diao, S., Zhang, F., & Wang, Y. (2019). A survey on image segmentation methods with convolutional neural networks. *Journal of Computational and Graphical Statistics*, 28(3), 583-600.